

Credit Card Fraud Detection

1.1. Introduction

Setiap tahun ada miliaran dolar kerugian yang disebabkan oleh penipuan transaksi kartu kredit. Berbagai cara telah diupayakan dan teknologi telah dikembangkan untuk mendeteksi adanya penipuan pada transaksi kartu kredit. Algoritma Machine Learning pun semakin dikembangkan untuk dapat melakukan klasifikasi agar dapat melakukan analisa pada semua transaksi yang sah dan memberikan peringatan pada transaksi yang mencurigakan. Peringatan itu kemudian memberitahukan kepada pemegang kartu apakah transaksi tersebut asli atau tidak. Pada kenyataannya, masalah sangatlah menantang dari perspektif Machine Learning, karena adanya distribusi kelas yang sangat tidak seimbang, yaitu transaksi yang sah jauh lebih banyak daripada penipuan dan beberapa transaksi yang mendapat label khusus.

1.2. Related Work

Ada beberapa hal yang menjadi fokus tantangan pada pengembangan algoritma machine learning untuk mendeteksi penipuan transaksi yaitu

A. Supervised & Unsupervised

Telah banyak digunakan metode digunakan untuk mendeteksi fraud baik itu supervised maupun unsupervised. Metode supervised mengasumsikan bahwa data transaksi masa lalu tersedia namun sering kali mengalami keterbatasan dalam mengenali transaksi yang terjadi sekarang. Namun disini lain metode supervised dapat digunakan untuk mengenali transaksi yang tidak sama dengan kondisi normalnya dengan memodelkan sebagian besar transaksinya.

Beberapa metode supervised mendeteksi fraud yang sering digunakan seperti neural network, metode rule-based (BAYES, RIPPER) dan algoritma tree-based..

B. Unbalanced Data Problem

Memperlajari dataset yang tidak seimbang adalah tantangan tersulit karena sebagian besar sistem machine learning tidak dirancang untuk mengatasi perbedaan yang besar antara jumlah kasus yang dimiliki masing-masing kelas

Belajar dari kumpulan data yang tidak seimbang adalah tugas yang sulit karena sebagian besar sistem pembelajaran tidak dirancang untuk mengatasi perbedaan besar antara jumlah kasus yang dimiliki masing-masing kelas.

Beberapa metode untuk menangani unbalancing data ialah dengan melakukan undersampling atau pun oversampling.

C. Incremental Learning

Static Learning adalah jenis pembelajaran klasik dimana dataset diproses sekaligus dalam satu batch pembelajaran. Incremental Learning diinterpretasikan bahwa data sebagai aliran berkelanjutan dan diperbaharui setiap terdapat perubahan atau data baru. Dalam konteks ini penting untuk melestarikan pengetahuan yang diperoleh sebelumnya serta memperbaruinya dengan benar.

1.3. Dataset & Features

1.3.1. Dataset

Dataset yang digunakan diperoleh secara online dari [Kaggle.com](https://www.kaggle.com) dan merupakan dataset yang telah dipublikasikan secara umum untuk tujuan pembelajaran. Dataset ini berisi transaksi kartu kredit yang dilakukan selama dua hari pada bulan September 2013 oleh pemegang kartu kredit Eropa. Dataset ini menyajikan transaksi penipuan sebanyak 492 penipuan dari 284.807 transaksi dengan kata lain terdapat data yang sangat tidak seimbang dimana kelas positif (penipuan) menyumbang 0,172% dari semua transaksi. Adapun dataset dibagi menjadi data training dan data test masing-masing sebesar 70% dan 30%.

1.3.2. Features

Dataset terdiri dari 284.807 baris dan 31 kolom dengan keterangan masing-masing kolom sebagai berikut :

V1, V2, ... V28	: komponen utama yang diperoleh melalui Principal Component Analysis PCA.
Time	: waktu yang berlalu (dalam detik) antara transaksi saat ini dan transaksi pertama.
Amount	: jumlah transaksi.
Class	: variabel respon dan dibutuhkan nilai 1 jika terjadi fraud dan 0 jika sebaliknya.

Pada fitur V1 hingga V28 dilakukan analisa distribusi Class untuk mencari fitur yang memberikan pengaruh pada penentuan fraud dan diperoleh bahwa Sementara itu pada Analisa Fitur Time dan Amount tidak berada pada skala yang sama dengan Fitur Class maupun V1 hingga V28. Adapun setelah dilakukan Analisa distribusi Class pada komponen V1 hingga V28 diperoleh bahwa "V28", "V27", "V26", "V25", "V24", "V23", "V22", "V21", "V20", "V15", "V13", "V8", "V7", "V6", "V5" tidak akan dilibat sebagai predictor.

1.4. Metode

Pada kesempatan ini, kita akan fokus pada tiga metode supervised machine learning untuk klasifikasi yaitu

- Rule-based algorithm : Gaussian Naïve Bayes Classifier yaitu metode machine learning yang memanfaatkan perhitungan statistic dan probability untuk melakukan klasifikasi.
- Tree-based algorithm : Decision Tree Classifier yaitu metode machine learning yang memanfaatkan pengelompokan karakteristik pada fitur tertentu.
- Oleh karena, prediksi yang akan dilakukan didasarkan pada analisa komponen utama yang memiliki skala yang sama maka kita akan melibatkan Linear Regression untuk melihat hubungan variable yang juga akan menentukan hasil prediksi.

Untuk mengatasi imbalance pada data digunakan metode undersampling yaitu menyeimbangkan data dengan memotong jumlah data pada Class Mayoritas. Pada kesempatan ini tidak digunakan metode Oversampling dengan mempertimbangkan untuk menghindari overfitting.

1.5. Experiment Result & Discussion

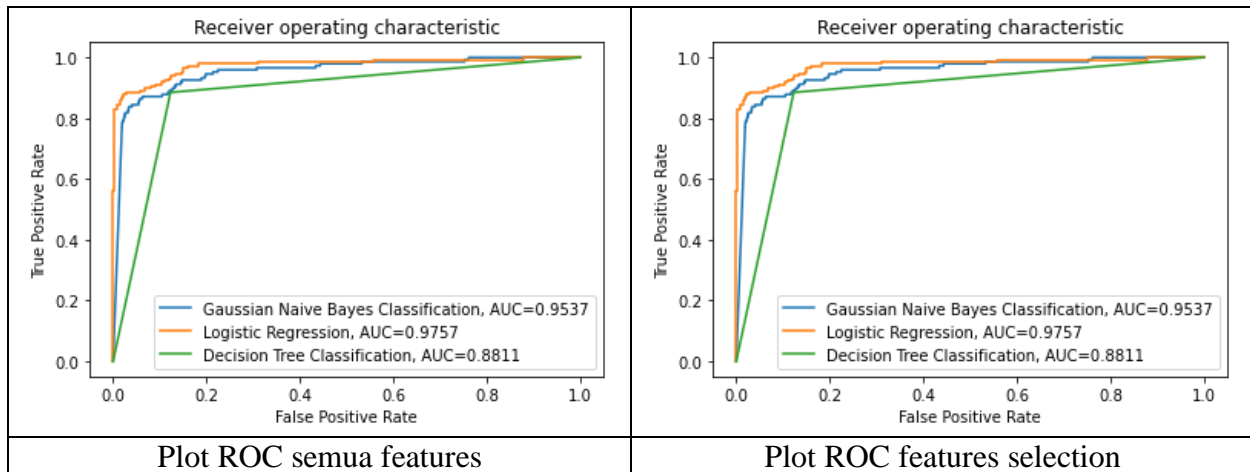
a. Hasil dengan menggunakan semua features yang ada

Gaussian NB Classifier	recall score : 0.8378378378378378 precision score: 0.04069576632753528 f1 score : 0.07762128325508608 accuracy score : 0.9655091698559274 ROC AUC : 0.9536666465985301
Logistic Regression	recall score : 0.831081081081081 precision score: 0.13697104677060135 f1 score : 0.23518164435946465 accuracy score : 0.9906370328757184 ROC AUC : 0.9756717148592405
Decision Tree Classifier	recall score : 0.8783783783783784 precision score: 0.012526498361919445 f1 score : 0.024700741022230667 accuracy score : 0.8798497243776553 ROC AUC : 0.8791153278843062

b. Hasil dengan menggunakan features selection

Gaussian NB Classifier	recall score : 0.8378378378378378 precision score: 0.04069576632753528 f1 score : 0.07762128325508608 accuracy score : 0.9655091698559274 ROC AUC : 0.9536666465985301
Logistic Regression	recall score : 0.831081081081081 precision score: 0.13697104677060135 f1 score : 0.23518164435946465 accuracy score : 0.9906370328757184 ROC AUC : 0.9756717148592405
Decision Tree Classifier	recall score : 0.8918918918918919 precision score: 0.012321478577429292 f1 score : 0.02430715403738146 accuracy score : 0.8759757967299837 ROC AUC : 0.8839200358691537

c. Plot ROC AUC



1.6. Conclusion & Future Works

- Linear Regression memberikan sensitivitas model yang lebih baik, tetapi nilai prediksi positif untuk Naive-Bayes lebih baik. Naive-Bayes hanya merupakan probabilitas sederhana. Tidak ada koefisien. pengoptimalan dengan menyesuaikan. Sementara itu Decision Tree memberikan nilai prediksi positive tertinggi, namun akurasi berubah seiring dengan fitur yang berubah dengan kata lain Decision Tree sensitive terhadap perubahan data. Selain itu Decision tree memberikan nilai Area Under Curve yang terendah.

1.7. Reference

- Dal Pozzolo, Andrea Adaptive Machine learning for credit card fraud detection ULB MLG PhD thesis (supervised by G. Bontempi)
- Dal Pozzolo, Andrea; Boracchi, Giacomo; Caelen, Olivier; Alippi, Cesare; Bontempi, Gianluca. Credit card fraud detection: a realistic modeling and a novel learning strategy, IEEE transactions on neural networks and learning systems,29,8,3784-3797,2018,IEEE
- Fabrizio Carcillo, Yann-Aël Le Borgne, Olivier Caelen, Frederic Oblé, Gianluca Bontempi Combining Unsupervised and Supervised Learning in Credit Card Fraud Detection Information Sciences, 2019
- Dal Pozzolo, Andrea; Caelen, Olivier; Le Borgne, Yann-Ael; Waterschoot, Serge; Bontempi, Gianluca. Learned lessons in credit card fraud detection from a practitioner perspective, Expert systems with applications,41,10,4915-4928,2014, Pergamon